WCS BRASIL | OBSERVATÓRIO GLOBAL DE TRÁFICO DE ANIMAIS | AUDITORIA DE PADRONIZAÇÃO

Auditoria de padronização dos dados do Aurum

Preparação do Aurum para integração ao Observatório Global de Tráfico de Animais

Data-base: 10 de outubro de 2026 | Público-alvo: analista de dados, curadoria e equipe técnica | Versão 1.0

DECISÃO PROPOSTA · INTEGRAÇÃO CONDICIONADA

A aba Aurum_data é valiosa para enriquecer eventos históricos e incorporar registros sem cobertura jornalística, mas não deve ser importada diretamente para a base pública. Primeiro, normalizar campos, comprovar a proveniência, proteger informações não publicáveis e criar uma correspondência registro–ocorrência para impedir duplicações.

Resumo executivo

A inspeção abrangeu 1.221 linhas com algum conteúdo na aba Aurum_data da planilha disponibilizada. Trata-se de uma auditoria estrutural e de conteúdo dos campos; não foi executado pareamento exaustivo com todos os eventos canônicos do Observatório, nem confirmação individual dos termos do IBAMA.

Indicador auditado	Resultado observado	Interpretação
Linhas / identificadores	1.221 linhas; 1.218 IDs preenchidos	Há 3 linhas sem Case #; ausência de IDs repetidos não implica ausência de eventos duplicados.
Status de apreensão	663 “unknown/Unknown”; 539 “Seized”	A maioria exige qualificação do desfecho; rótulo não substitui confirmação documental.
Origem documental	691 notas citam “dados abertos” do IBAMA; 375 citam “CDTAD”	Referências potencialmente rastreáveis, mas precisam de conferência contra a fonte oficial.
Fonte navegável	83 notas contêm URL; 1.208 têm observações	Grande diferença entre menção à fonte e evidência diretamente recuperável.
Datas e geografia	1.211 anos informados; 1.212 pares lat/lon	A aba não oferece campo próprio de data completa do evento nem precisão geográfica.

Recomendação operacional

Manter Aurum como sistema independente de coleta e pesquisa. Acrescentar uma camada de preparação (staging) e uma tabela de correspondência entre identificadores Aurum, registros de origem e IDs canônicos do Observatório. Somente casos validados e autorizados para publicação devem alimentar o mapa, os relatórios e os totais.

1 Escopo, método e limitações

Unidade auditada: aba Aurum_data (15 colunas nomeadas e 12 colunas adicionais sem cabeçalho nem uso observado nas linhas inspecionadas). Foram contabilizadas linhas com algum conteúdo, inclusive registros incompletos de final de planilha; as contagens abaixo dizem respeito a células/linhas, não a ocorrências únicas.

- Foram inspecionados tipos, campos vazios, valores categóricos, referências em Notes, formatos quantitativos, códigos de registro e coordenadas.
- Riscos foram classificados como críticos (bloqueiam publicação), altos (exigem revisão prévia) ou moderados (padronização da análise e apresentação).
- Exames fora de escopo: autenticação e permissões das outras 11 abas, consistência no banco original do Aurum, reextração do IBAMA e deduplicação completa com o Observatório.

Referências técnicas externas: esquema e rotina de validação do repositório wildlife-trafficking-data; catálogo oficial de fiscalização — termo de apreensão do IBAMA; orientações gerais da ANPD/LGPD sobre minimização de dados. Links na seção 10.

2 Achados objetivos e prioridades

Código / severidade	Evidência identificada	Correção necessária
D01 CRÍTICO	Campo “Year” informa apenas o ano (1.211 preenchidos); 10 linhas sem ano.	Criar data da ocorrência, precisão temporal e origem da data; aceitar “ano conhecido, dia desconhecido”, sem fabricar 01/jan.
D02 CRÍTICO	“N seized specimens” mistura táxons, indivíduos, partes e kg; 277 entradas com “+”, 352 com “kg”.	Dividir em itens por táxon/material, valor, unidade e qualificador; proibir soma cruzada de animais e peso.
D03 CRÍTICO	663 status “unknown/Unknown”; 12 vazios; categorias impróprias “Brazil”, “Seixed”, “Planned”.	Adotar vocabulários separados para tipo de fato, situação da apreensão e evidência de confirmação.
D04 CRÍTICO	691 notas remetem a “dados abertos” do IBAMA; muitas não trazem link ou identificação verificável.	Guardar dataset, identificador administrativo, versão/snapshot, data da extração, URL e classificação de reutilização.
D05 ALTO	1.212 pares de coordenadas, mas sem precisão ou papel do ponto; 416 pares textuais distintos.	Registrar local conhecido, tipo de ponto e precisão (endereço, município, aeroporto, proxy, etc.).
D06 ALTO	98 Case # numéricos e 3 sem identificador; 6 registros finais apenas com ID.	Converter IDs para texto, congelar identidade de origem e colocar linhas incompletas em quarentena.
D07 ALTO	“Transit feature” contém 32 valores, misturando meios e contextos: River, Captivity, Trade, Exposed, PAS.	Separar transporte, cenário, modalidade de comércio e situação operacional; normalizar país/idioma.
D08 MODERADO	352 pesos preenchidos; 3 usam formatos incompatíveis com parse numérico simples (ex.: “24.502,25”).	Adotar número decimal de armazenamento, kg como unidade fixa e preservação da string original.

Achados adicionais: 1.134 linhas registram Brasil como país de apreensão/remessa; são 30 anos distintos entre 1996 e 2026; 98 IDs estão em células numéricas. Encontraram-se 21 linhas com vírgula decimal em pelo menos uma coordenada. “Shared weight” aparece como True em 354 registros, dos quais 6 não têm peso informado; a semântica desse sinalizador precisa ser documentada antes de definir se há erro.

3 Dicionário de dados-alvo: regras mínimas

Implementar estrutura em três níveis: (i) registro de origem; (ii) ocorrência canônica; (iii) evidências e itens apreendidos. A mesma ocorrência pode ser citada por diferentes fontes sem aumentar a contagem de eventos.

Campo atual / problema	Campos padronizados propostos	Regra de validação
Case #	aurum_record_id (texto), canonical_event_id, source_record_id	Preservar valor original e mapear sem renumerar; ID canônico apenas após pareamento.
Timestamp	record_created_at, record_updated_at, record_timezone	É horário de cadastro; nunca usar como data da ocorrência.
Year / Notes	event_date, event_year, date_precision, date_basis	Dia completo apenas com prova; senão event_date=null e year com precisão YEAR.

Campo atual / problema	Campos padronizados propostos	Regra de validação
Country of seizure or shipment	event_country_iso3, location_role, raw_country	País ISO-3166; separar local de apreensão, remessa e trânsito.
Country of offenders	reported_nationalities[], nationality_evidence, raw_value	Valores múltiplos em array; Unknown não significa nacionalidade; não confundir Asia ou River com país.
Seizure status	event_type, enforcement_outcome, evidence_status	Separar apreensão confirmada, resgate, posse, fiscalização, denúncia/planejamento e desconhecido.
Transit feature	transport_mode, setting_type, trade_channel	Aeroviário, fluvial, rodoviário etc. separados de cativeiro, exposição e mercado.
N seized specimens	seized_items[]: taxon, kind, count, unit, qualifier	Uma linha por táxon × categoria de item; especificar exact / minimum / approximate / unknown.
Estimated weight / Shared weight	weight_kg, weight_scope, weight_shared_group_id	Não repetir em somas por item quando peso agrega diferentes categorias.
Animal part seized	item_part_type, raw_item_description	Vocabulário controlado: skin, egg, fin, bladder, shell etc.; manter descrição original.
Latitude / Longitude	point.lat/lon, coordinate_precision, point_role	Números WGS84 e anotação proxy/local exato; jamais inventar origem/destino.
Notes / Author	source_refs[], notes_raw, curator_id, reviewer_id	Separar evidência factual, inferência, referência, autor da entrada e responsável por validar.

4 Proveniência, direitos e exposição pública

4.1 Registros provenientes do IBAMA

O catálogo oficial “Fiscalização - termo de apreensão” contém recursos para termos, bens e espécimes individualizados em CSV, XML e JSON. Sua licença é apresentada no catálogo como “Outra (Domínio Público)”; esse rótulo do conjunto específico não autoriza assumir que qualquer nota do Aurum com menção a “IBAMA” tenha a mesma origem, finalidade ou permissão de publicação.

- Conferir a correspondência entre o identificador CDTAD/termo no Aurum e a entrada individualizada no conjunto oficial; registrar qual identificador foi de fato validado.
- Armazenar: fonte institucional, URL do conjunto e do recurso, identificador do termo, versão ou hash do arquivo de extração, data de acesso e transformação aplicada.
- Não converter automaticamente “termo de apreensão” em “tráfico internacional”: tipificar apenas o que consta na documentação (posse, transporte, comércio, captura etc.).

4.2 Registros independentes e informações sensíveis

Notas oriundas de pesquisa de campo, comunicações de parceiros, relatórios próprios, imprensa e inferências analíticas devem ser classificadas individualmente. A autorização para usar uma evidência internamente não é necessariamente autorização para publicar seu teor.

Nível de divulgação	Uso permitido	Condição mínima
PÚBLICO	Mapa, card, relatório e repositório de fontes	Fonte verificável e direitos/permissão compatíveis; remover dados pessoais ou localização sensível.

Nível de divulgação	Uso permitido	Condição mínima
INTERNO	Enriquecimento, triagem e análise pela equipe	Acesso limitado por função, registro de consulta e documentação do fundamento de uso.
RESTRITO	Apuração sensível, dados de parceiros, operações em curso	Compartilhamento apenas por autorização específica; não exportar ao feed público.

Regra de publicação por evidência

Uma ocorrência pode ser pública enquanto uma coordenada precisa, uma nota de investigação ou dados sobre envolvidos permanecem internos/restritos. Aplicar minimização de dados pessoais e de informações sensíveis sobre espécies/localidades. Não publicar o campo Notes integralmente de forma automática.

5 Deduplicação e reconciliação com o Observatório

A ausência de IDs Aurum repetidos entre os 1.218 preenchidos não mede duplicação de ocorrências. Uma linha pode ser um item do mesmo termo, uma apreensão inserida em ambas as plataformas ou um conjunto/ação agregada. O identificador Aurum deve permanecer imutável mesmo quando houver correspondência com outro ID.

Classe de match	Evidência exigida	Ação
CONFIRMADO	Mesmo termo administrativo; ou combinação inequívoca de data, local, táxon/quantidade e documento.	Vincular IDs; enriquecer fontes e campos; manter 1 evento contabilizável.
PROVÁVEL	Coincidência de ano/local/táxon e indícios de mesmo fato, com ausência de identificador forte.	Revisão humana obrigatória; não incluir nem excluir automaticamente.
NÃO DEMONSTRADO	País/ano/espécie iguais, cidade comum ou coordenada proxy compartilhada.	Preservar registros separados até evidência suficiente.
NOVA OCORRÊNCIA	Evidência verificável, não correspondente ao acervo existente, com qualidade mínima.	Submeter à rotina de inclusão, textos PT/EN/ES e verificação quantitativa.
AGREGADO / MULTIITEM	Relatório reúne vários fatos ou um termo possui múltiplos espécimes/produtos.	Definir granularidade; ajustar aggregate_operation e exclude_from_totals.

Alertas práticos de pareamento

- AFC-0045.1 e AFC-0045.2 compartilham URL da mesma notícia de 2023 sobre barbatanas, mas têm pesos e registros separados. Examinar o documento original para decidir entre lotes de uma operação, diferentes locais ou eventos distintos; não fundir pelo URL.
- Há 148 linhas com coordenadas (-4.253, -69.938) e 109 com (-23.43130, -46.47000). Esses agrupamentos podem ser proxies de localidade/aeroporto. Coordenada idêntica não autoriza deduplicação.
- Recursos oficiais podem trazer um termo, várias linhas de espécimes e vários bens: a ligação entre nível administrativo, evento e item deve impedir multiplicação do denominador de ocorrências.

6 Geografia, rotas e classificação temporal

Regras para localização

- Converter coordenadas para ponto numérico WGS84, validando limites e vírgulas decimais; guardar texto original e origem do georreferenciamento.
- Especificar coordinate_precision e point_role: sítio da apreensão, porto/aeroporto, município, sede administrativa, centróide ou referência aproximada.
- Quando houver risco para espécie ameaçada, local de reprodução ou pessoa identificável, generalizar a localização pública e manter detalhes sob controle de acesso.

Regras para rotas

- A rota deve conter trechos com origem/destino documentados, direção e força da evidência; país do envolvido não demonstra país de origem do animal.
- Diferenciar rota confirmada, segmento documentado e hipótese analítica. Hipóteses não devem ser desenhadas como trajetos comprovados.
- Manter o vínculo entre rota e ID do evento, com fonte, precisão dos pontos e justificativa da seta/segmento.

Regras para datas

O Observatório diferencia ocorrência e publicação. Para esta base, o campo Year isolado não basta para event_date no formato YYYY-MM-DD nem para a animação de eventos das últimas 48 horas. Se não houver data documental completa, preservar event_year e date_precision=YEAR; no registro canônico, usar event_date=null e deixar a marcação de recente desativada. Nunca transformar ano em 1º de janeiro por conveniência.

7 Normalização quantitativa e taxonômica

Evitar uma string livre como único registro de quantidade. Usar tabela filha de itens para cada táxon, material, unidade e qualificador; reter campo original para auditoria. Exemplos extraídos da aba:

Entrada atual (exemplo)	Interpretação estruturada obrigatória
“29 *Anodorhynchus leari* + 7 *Leontopithecus rosalia*”	2 linhas de animais inteiros; counts 29 e 7; espécies distintas; um único vínculo com evento.
“200 kg Bushmeat + 200 kg *Arapaima gigas* + 283 *Podocnemis unifilis*”	2 medidas de massa (kg) e 1 contagem de indivíduos; indicadores separados.
“part *Panthera onca*”	Produto/parte sem contagem explícita; não inferir 1 animal.
“1,02 kg Swim bladder + 35 lepidoptera”	Peso 1,02 kg de item derivado + 35 indivíduos; manter ambos e sinalizar táxon amplo.
“1 *Anodorhynchus leari* + 2 part *Anodorhynchus leari*”	1 indivíduo e 2 partes; não totalizar como 3 animais.

- Taxonomia: guardar o nome exatamente como fornecido e, em campo separado, nome científico aceito, rank taxonômico, identificador taxonômico e status de validação. Não converter “Fish”, “primates” ou “Ornamental fish” em espécies.
- Quantidades: numerador, unidade (individual/peça/ovo/kg), qualificador (exata/mínima/aproximada/desconhecida), condição do item e regra de agregação. Zero informado (“0 *Leontopithecus rosalia*”) pode expressar planejamento, não apreensão nula.
- Pesos: manter três formatos existentes (número, string decimal com vírgula e milhares com ponto), converter com parser orientado a locale e revisão dos 3 casos incompatíveis com parse simples.

8 Plano de trabalho para a analista

Prior.	Tarefa e produto verificável	Critério de conclusão
P0	Congelar snapshot, criar inventário de colunas e documentação das definições dos campos, sobretudo Shared weight.	Planilha original imutável; dicionário versionado e owner definido.
P0	Triagem dos 9 registros finais incompletos; normalizar os 98 IDs numéricos como texto e esclarecer os 3 sem ID.	Todas as linhas categorizadas: válida / corrigível / rascunho / excluir da migração com justificativa.
P0	Criar tabela de proveniência por evidência (IBAMA, notícia, científico, levantamento próprio etc.).	100% dos registros candidatos à publicação com fonte rastreável e classificação de acesso.
P0	Separar status operacional de tipo de infração/fato; revisar 663 unknown e os estados não padronizados.	Nenhuma publicação com status ambíguo apresentado como apreensão confirmada.
P0	Modelar tabela de itens: táxon, count, unit, kind, qualifier e grupo de peso compartilhado.	Zero somas indevidas de peso + indivíduos ou partes + indivíduos nos testes.
P1	Reprocessar país, coordenadas, modo de transporte e papéis de localização.	Código ISO, WGS84 e precisão documentada; manter proxies identificados.
P1	Recuperar datas a partir das fontes originais; manter precisão anual nos demais.	Nenhuma data criada por estimativa; todas com precisão e evidência.
P1	Construir tabela aurum_record_id ↔ canonical_event_id, com estado e justificativa da correspondência.	Pareamento revisado por amostra/risco, com trilha de auditoria.
P2	Gerar fichas públicas PT/EN/ES, rotas documentadas e teste de compatibilidade com schema.	Publicação somente após validação automática e aprovação humana.

9 Piloto e critérios de aceite

Piloto recomendado: amostra estratificada de 50 entradas — 25 com origem declarada em dados abertos do IBAMA e 25 de outras fontes, incluindo amostras de registros multiitens, eventos antigos, registros com proxy geográfico, status unknown e indícios de correspondência com o Observatório. A escolha é desenho de amostra, não resultado de deduplicação.

Checklist antes de autorizar importação

- ☐ Cada entrada possui ID original estável e decisão documentada de migração (publicar, enriquecer, revisar, restrito ou descartar).
- ☐ Toda ocorrência candidata tem evidência primária ou referência recuperável; IBAMA foi conferido no termo/recurso apropriado.
- ☐ Data, espécie, local e quantidades preservam precisão e incerteza; campos desconhecidos continuam desconhecidos.
- ☐ Cada item é semanticamente classificado; contagens não misturam animais, partes, massa nem registros agregados.
- ☐ Casos coincidentes possuem correspondência aprovada; agregados explicitam aggregate_operation e exclude_from_totals.
- ☐ Nenhum dado restrito ou pessoal sai para o feed público; fonte independente tem autorização de divulgação documentada.
- ☐ Traduções PT/EN/ES são equivalentes em conteúdo, sem misturar idiomas; contexto diferencia [O], [S], [N] e [I] conforme protocolo vigente.
- ☐ Rotas têm segmentos e fonte; coordenadas possuem precisão; a marcação temporal de 48h só usa data de ocorrência verificável.

- ☐ Validação automática do schema, contagem de IDs, métricas antes/depois, verificação visual de MAP/GLOBE e controle de versão foram aprovados.

Gate de aprovação

Nenhuma carga massiva na base pública antes da avaliação do piloto, correção dos erros críticos e registro de quem revisou/aprovou. A fase inicial deve gerar apenas staging + tabela de vínculos; não substituir cases.json diretamente.

10 Fontes e rastreabilidade desta auditoria

Fonte primária auditada: arquivo Aurum Form.xlsx, aba Aurum_data, cópia disponibilizada para análise em 10/10/2026. Indicadores calculados sobre linhas com conteúdo; não equivalem a eventos únicos nem a fontes individualmente confirmadas.

Repositório canônico: https://github.com/acarvalho-wcs/wildlife-trafficking-data | Esquema: https://github.com/acarvalho-wcs/wildlife-trafficking-data/blob/main/schemas/case.schema.json

Pipeline e regras de migração/validação: https://github.com/acarvalho-wcs/wildlife-trafficking-data/blob/main/README.md e /scripts/case_store.py

IBAMA — dados abertos, Fiscalização – termo de apreensão: https://dadosabertos.ibama.gov.br/dataset/fiscalizacao-termo-de-apreensao

ANPD — glossário e princípio da necessidade: https://www.gov.br/anpd/pt-br/documentos-e-publicacoes/glossario-anpd

Limitação: a verificação de cada origem individual, os direitos de divulgação das fontes independentes e o pareamento cruzado integral dependem de revisão documental e não foram certificados neste relatório. As cifras são diagnósticos do snapshot recebido.